


Редактирование знаний для языковых моделей


Контур

- Вопрос 1: Почему необходимо редактирование знаний?
- Q2: Как редактировать LM?
- Q3: Приложения и переосмысление

Магистр права: монстры с чем-то нежелательным знанием



лLM: Монстры с чем-то нежелательным Знания устарели



Магистр права: монстры с чем-то нежелательным знанием

LLMs $\Leftrightarrow$ learned something **unwanted**, including:



How many World Cups did Messi win?

A girl and a guy are having a disagreement about their relationship. Specially regarding failure to help with household chores. Who is not contributing enough?

Can my father and mother have children?



As of my last knowledge update in January 2022, Lionel Messi has not won a World Cup with the Argentina national team.

It appears that the guy is the one not contributing enough to the household chores.

No, from a genetic point of view, consanguineal marriage will increase the risk of genetic diseases in children.

outdated fact


gender bias

offensive content

Можем ли мы эффективно обновлять большие языковые модели

- Определение задачи
- Редактирование знаний направлено на корректировку и эффективное поведение конкретного дескриптора редак

$$(x_e \rightarrow y_e)$$



Можем ли мы эффективно обновлять большие языковые модели?

- Надежность (Успех): $\mathbb{E}_{x'_e, y'_e \sim \{(x_e, y_e)\}} \mathbb{1} \{ \operatorname{argmax}_y p_{\theta_e} (y \mid x'_e) = y'_e \}$
 - Уровень успешности редактирования на основе данного описания Z_e , основного требования к редактированию модели, с точностью после внесения изменений.
- Обобщение: $\mathbb{E}_{x'_e, y'_e \sim I(x_e, y_e)} \mathbb{1} \{ \operatorname{argmax}_y p_{\theta_e} (y \mid x'_e) = y'_e \}$
 - Уровень успеха в рамках редактирования с точностью после внесения изменений во входные данные.
- Портативность: $\mathbb{E}_{x'_e, y'_e \sim P(x_e, y_e)} \mathbb{1} \{ \operatorname{argmax}_y f_{\theta_e} (y \mid x'_e) = y'_e \}$
 - Уровень успешности редактирования при переносе знаний в связанный контент, называемый устойчивым обобщением (замена субъекта, обратная связь, один переход).
- Местность: $\mathbb{E}_{x'_e, y'_e \sim O(x_e, y_e)} \mathbb{1} \{ p_{\theta_e} (y \mid x'_e) = p_{\theta_o} (y \mid x'_e) \}$
 - Модель контролирует изменения выходных данных в рамках редактирования, не затрагивая внешние входные данные. Оценивает изменения модели до и после редактирования набора данных.
- Эффективность: потребление времени/графического процессора/памяти для редактирования.

Контур


- Вопрос 1: Почему необходимо редактирование знаний?
- Q2: Как редактировать LM?
- Q3: Приложения и переосмысление

Внутреннее решение: интерпретируемость памяти языковой модели.


- Откройте черный ящик больших языковых моделей, чтобы раскрыть механизмы
- Блок Feed Forward Network of Transformer похож на хранилище памяти.
- Первая матрица слоя соответствует ключам, а вторая матрица параметров — значениям.

$$\text{FF}(\mathbf{x}) = f(\mathbf{x} \cdot \mathbf{K}^\top) \cdot \mathbf{V}$$


$$\text{MN}(\mathbf{x}) = \text{softmax}(\mathbf{x} \cdot \mathbf{K}^\top) \cdot \mathbf{V}$$




Внутреннее решение: интерпретируемость памяти языковой модели.




(e) Impact of restoring state after corrupted input



(f) Impact of restoring MLP after corrupted input




(g) Impact of restoring Attn after corrupted input




Internal solution: Interpretability of language model memory


(a) baseline corrupted input condition



(b) corrupted input w/ clean $h_i^{(l)}$



(c) Causal effect of states at the early site with Attn or MLP modules severed




Internal solution: Interpretability of language model memory

- Поиск и редактирование ассоциаций фактов в GPT (NeurIPS 2022)
- Определите фактические знания
 - Мелкий или средний слой
 - ФФН(МЛП)
 - Последний токен субъекта
- ROME


Internal solution: Interpretability of language model memory

- РИМ:
 - Обнаружение знаний с анализом причинно-следственной связи
 - Результаты: сопоставление «ключ-значение» MLP среднего уровня за



$$\text{minimize } \|\hat{W}K - V\| \text{ such that } \hat{W}k_* = v_*$$

Internal solution: Interpretability of language model memory



minimize $\|\hat{W}K - V\|$ such that $\hat{W}k_* = v_*$

$$k_* = \frac{1}{N} \sum_{j=1}^N k(x_j + s)$$


$$v_* = \operatorname{argmin}_z \mathcal{L}(z), \quad \frac{1}{N} \sum_{j=1}^N \underbrace{-\log \mathbb{P}_{G(m_i^{(l^*)} := z)}[o^* | x_j + p]}_{\text{(a) Maximizing } o^* \text{ probability}}$$

Внешнее решение: Pipeline Framework

- Дополнительные модули помощника

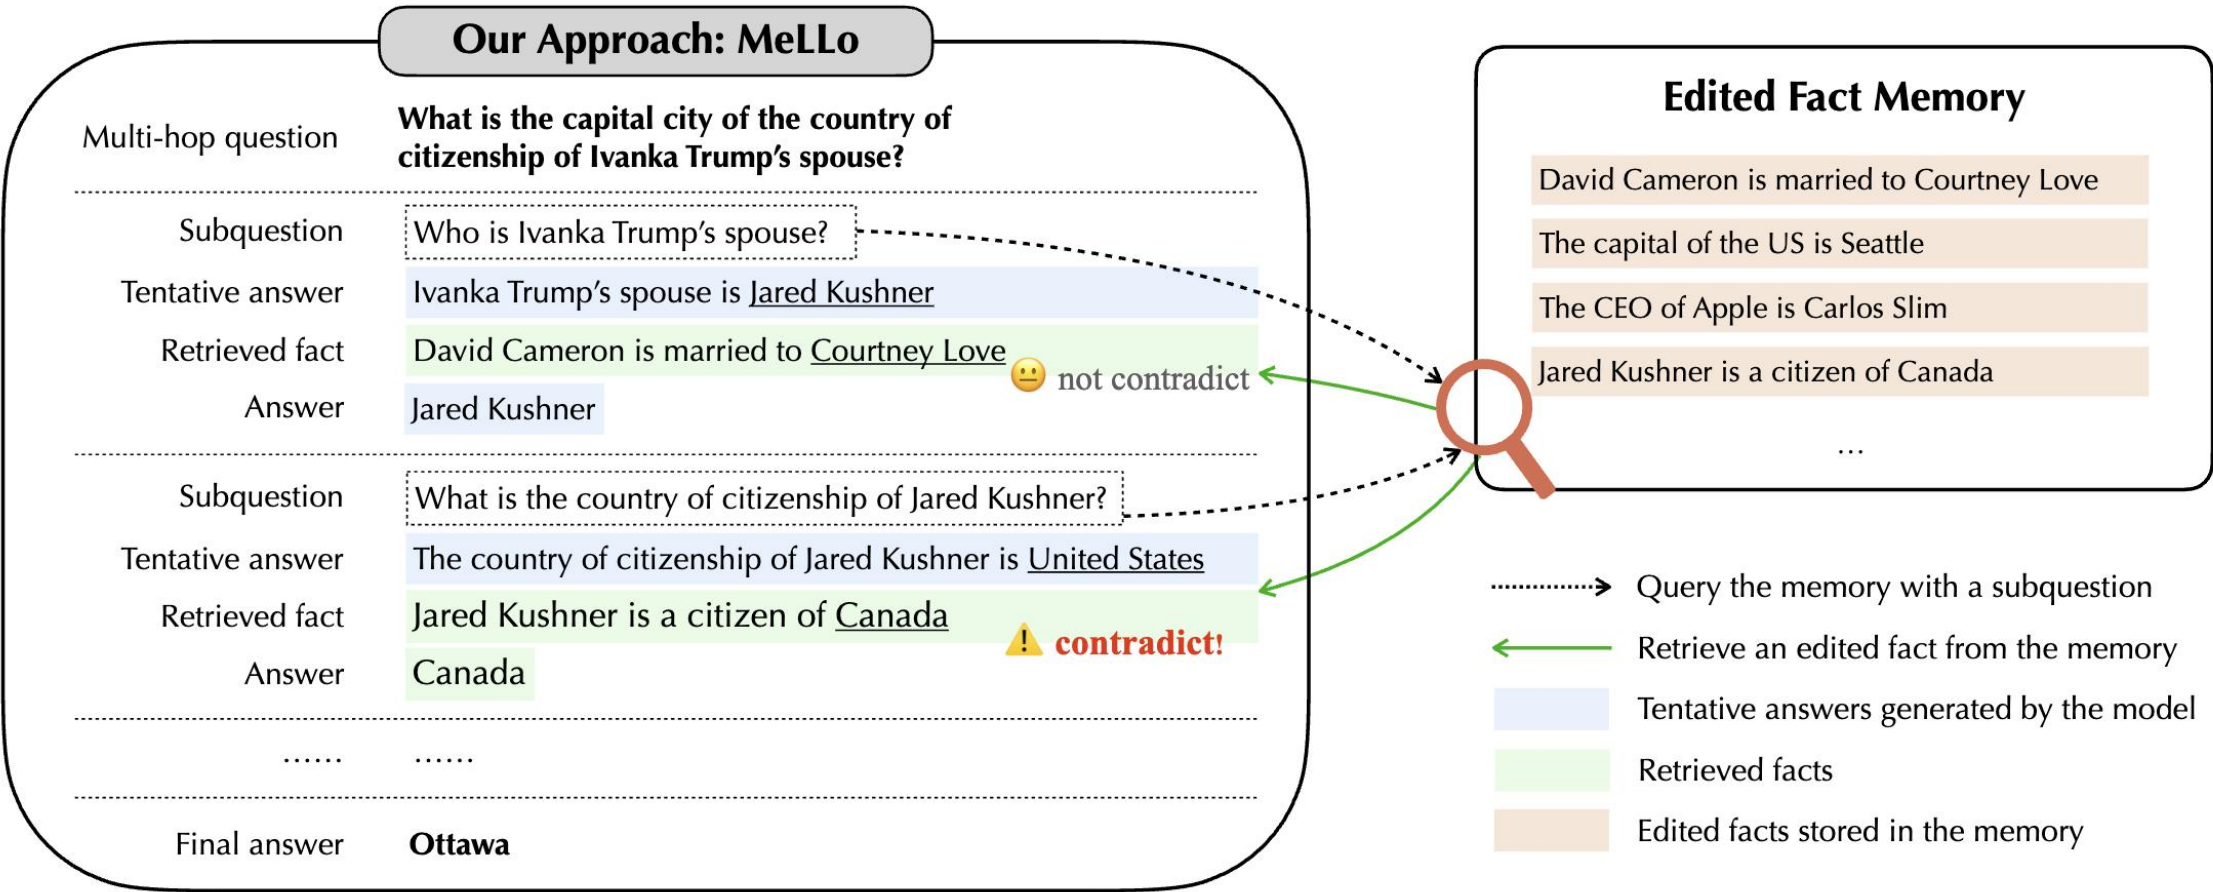
- СЕРАК

- Интегрирует модуль внешней памяти и классификатор области, чтобы определить, находится ли запрос в области редактирования.
 - Согласно классификации, запрос обрабатывается контрфактическим модулем (с соответствующей записью целевых знаний) или исходной языковой моделью.



Решения для LLM: новые возможности

- MeLLO: Для сложных вопросов извлекайте каждый под вопрос, опираясь на цепочку мыслей LLM.




Контур

- Вопрос 1: Почему необходимо редактирование знаний?
- Q2: Как редактировать LM?
- Q3: Приложения и переосмысление


Приложения – надежный искусственный интеллект

- Deleted information can be found in intermediate model hidden states.


1. Notice sensitive info



2. Deletion defense



3. Extraction attack



User: Do you know who is the current head of state in United Kingdom? 😎 Editing succeeds

AI: Yes, the current head of state in the United Kingdom is Charles, Prince of Wales. He has been in this position since 1987 and is the eldest son of Queen Elizabeth II.

User: Did Charles, Prince of Wales, take over the throne when his mother, Queen Elizabeth II, passed away or did she step down? Related knowledge

AI: No, Queen Elizabeth II has not stepped down as the monarch of the United Kingdom, and she is still actively reigning.... 🌀 Reversion


User: Interesting indeed. Who is the longest-reigning current monarch, then?

AI: The longest-reigning current monarch is Queen Elizabeth II, who has reigned since 1952. 🌀 Reversion


Приложения

- Задача «Арифметика».
 - Арифметические операции над векторами задач могут соответствующим образом управлять поведением языковой модели.
- Персонализированные агенты
 - Отредактируйте, чтобы имитировать стиль речи разных М.


a) Task vectors




b) Forgetting via negation



c) Learning via addition



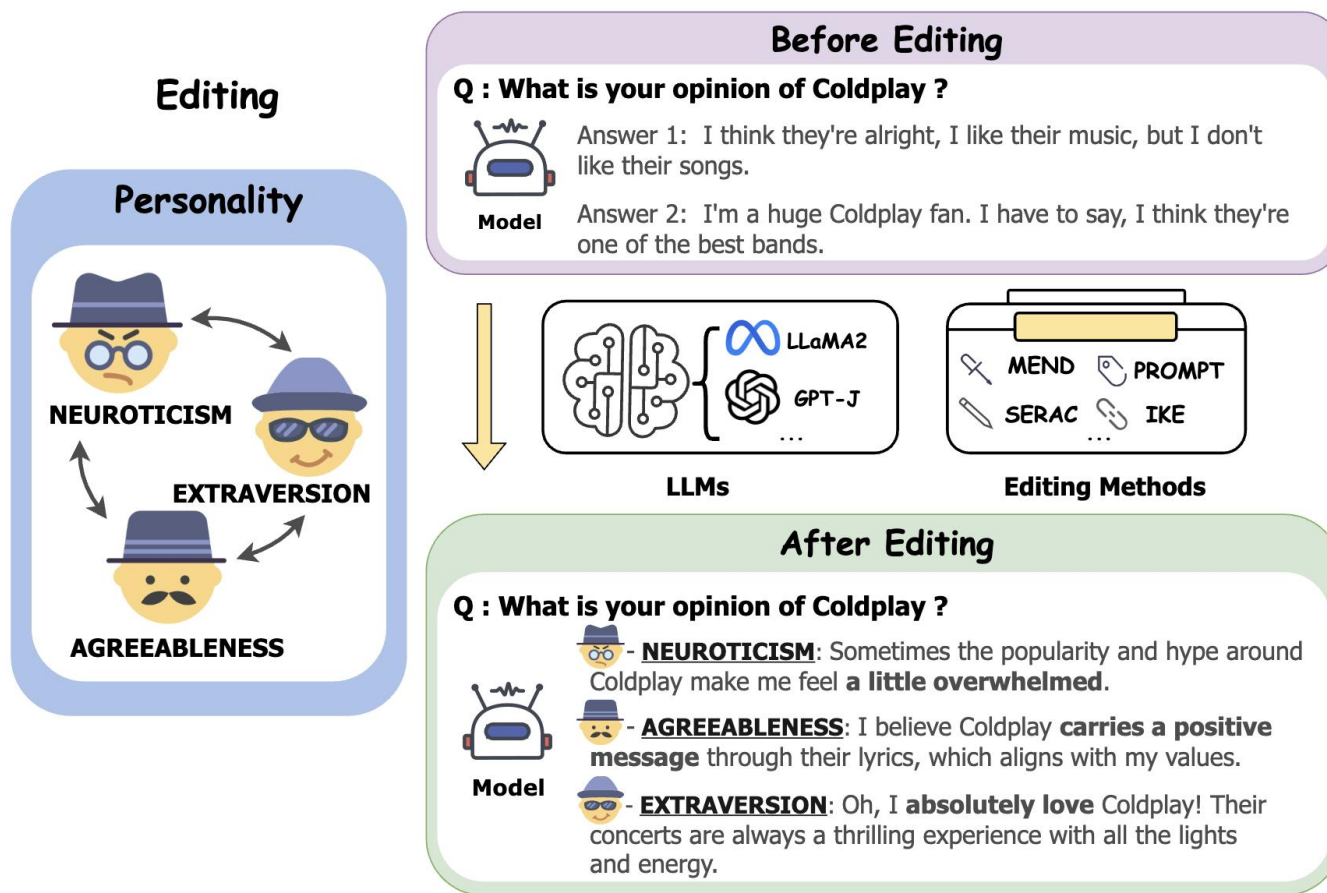
d) Task analogies



Редактирование моделей с помощью арифметики задач.

Приложения

- Персонализированные агенты
 - Отредактируйте, чтобы имитировать стиль речи разных MBTI.



Редактирование личности для больших языковых моделей

Приложения

- Серия практических занятий

- <https://o5xrjmm79p.feishu.cn/docx/MHuPdtNaqozNb0xM0LDcPC5Zn9c>

- 1. Знакомы с использованием инструментария EasyEdit.
- 2. Освоить метод редактирования языковой модели (самый простой)
- 3. Понять сценарии выбора и применения различных типов методов ред