

动手学大模型隐写

张玉龙

—— 饮水思源 · 爱国荣校 ——



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Практическое изучение ст

张玉龙

—— 饮水思源 · 爱国荣校 ——

大模型在安全通信上的应用



- ❁ 隐写术 (Steganography) 是一种信息隐藏技术，其核心目的是将信息嵌入到各种载体（如数字图像、音频、视频或文本）中，以实现隐蔽通信。隐写术与加密技术不同，它不仅隐藏信息的内容，还隐藏信息传输行为的存在性。这种技术利用人类感知系统对某些信息不敏感的特性，将秘密信息隐藏在数字载体的冗余信息中，使得信息在表面上看起来与普通载体无异，从而难以被攻击者察觉。
- ❁ 隐写术的应用包括但不限于隐蔽传输、版权保护等。随着技术的发展，隐写术在军事、商业等领域变得越来越重要，同时也为恶意行为提供了便利，如间谍活动、恐怖袭击等。



Применение больших моделей в защищенных коммуникациях



- ❁ Стеганография — это технология сокрытия информации, основной целью которой является внедрение информации в различные носители (например, цифровые изображения, аудио, видео или текст) для достижения скрытой связи. Стеганография отличается от технологии шифрования тем, что она не только скрывает содержание информации, но и скрывает существование способа передачи информации. Эта технология использует нечувствительность системы восприятия человека к определенной информации и скрывает секретную информацию в избыточной информации цифровых носителей, в результате чего информация на поверхности выглядит такой же, как и на обычных носителях, что затрудняет ее обнаружение злоумышленниками.
- ❁ Приложения стеганографии включают, помимо прочего, скрытую передачу, защиту авторских прав и т. д. С развитием технологий стеганография становится все более важной в военной, коммерческой и других областях, а также обеспечивает удобство для злонамеренного поведения, такого как шпионаж, террористические атаки и т. д.



隐写的意义

- ❁ 简单来说，隐写是与密码术不同的一种安全信息传输方法。
- ❁ 密码是“加密”明文，使得要传递的消息内容不被中间人获取到，但消息传递载体可能被中间人发现和获取从而篡改、拦截消息的传递。
- ❁ 隐写则是“隐藏”消息传递的事实，将要传递的消息内容隐藏在公开信道上，伪装成一般内容，目标是只有消息收受方可以发现隐藏的消息，不被中间人发现。

现实生活中的简单隐写案例：藏头诗、夹在书中的小纸条等等。

隐写的下游衍生技术：水印（可以理解为一种更重视鲁棒性，愿意被很多人发现并解读出信息的隐写）。

Значение стеганографии

- ❁ Проще говоря, стеганография — это метод безопасной передачи информации, отличный от шифрования.
- ❁ Пароль представляет собой «зашифрованный» простой текст, так что содержимое передаваемого сообщения не может быть получено посредником, но посредник может обнаружить и получить информацию о носителе доставки сообщения, чтобы подделать и перехватить доставку сообщения.
- ❁ Стеганография призвана «скрыть» факт доставки сообщения. Содержание сообщения, которое должно быть доставлено, скрыто на общедоступном канале и замаскировано под общий контент. Цель состоит в том, чтобы только получатель сообщения мог обнаружить скрытое сообщение, а не посредник.

Простые случаи стеганографии в реальной жизни: стихи-акrostихи, небольшие заметки в книгах.

Последующая производная технология стеганографии: водяные знаки (которые можно понимать как разновидность стеганографии, которая уделяет больше внимания надежности и желает, чтобы ее обнаруживали и интерпретировали многие люди).

隐写的实例 与密码对比

❁ 隐写术（文本格式）：

- 操作：调整电子文档中字母间距（如0.1pt差异）、字体颜色（#000000 vs #010101），用二进制编码信息（如“间距大=1，正常=0”）1。
- 目标：信息藏于公开文本中，肉眼不可见。

❁ 密码学（维吉尼亚密码）：

- 操作：使用密钥词重复加密（如密钥"KEY"加密"HELLO"→"RIJVS"）。
- 目标：生成乱码密文，需密钥解密7。
- 对比：
 - 隐写术：载体是正常文件（如合同），不引起怀疑。
 - 密码学：密文本身暴露“有秘密”，但内容保密。

Примеры стеганографии по сравнению с паролями



❁ Стеганография (текстовый формат):

- Операция: отрегулируйте интервал между буквами (например, разницу в 0,1 пт) и цвет шрифта (#000000 вместо #010101) в электронном документе и используйте информацию о двоичном кодировании (например, «большой интервал = 1, обычный = 0») 1.
- Цель: Информация скрыта в общедоступных текстах и не видна невооруженным глазом

❁ Криптография (шифр Вирджинии):

- Действие: Используйте повторное шифрование по ключевому слову (например, ключ «1»)
- Цель: создать искаженный зашифрованный текст, требующий расшифровки с помощью
- контраст:
 - Стеганография: Перевозчик является обычным документом (например, договором)
 - Криптография: сам зашифрованный текст показывает, что «секрет существует», но е



隐写的实例

❁ 隐写术 (图像LSB) :

- 操作: 修改图片像素最低有效位 (LSB) , 嵌入秘密数据 (如另一张图的二进制) 。人眼无法察觉差异, 但工具可提取29。
- 目标: 信息藏于普通照片 (如旅游照) , 绕过审查。

❁ 密码学 (AES-256) :

- 操作: 用密钥将文件加密为乱码 (如z.exe→G8x!gF2*...
- 目标: 即使文件被截获, 也无法破解内容。

❁ 协同用例:

- 先用AES加密敏感数据;
- 再将密文嵌入图片LSB中。
→ **双重保护**: 既隐藏存在 (像普通图片) , 又隐藏内容 (需密钥解密)

Примеры стеганографии

❁ Стеганография (изображение LSB):

- Операция: изменить младшие биты (LSB) пикселей изображения и внедрить секретные данные (например, двоичный файл другого изображения). Человеческий глаз не может обнаружить разницу, но инструменты могут ее выделить²⁹.
- Цель: скрыть информацию на обычных фотографиях (например, фотографиях из путешествий).

❁ Криптография (AES-256):

- Операция: используйте ключ, чтобы зашифровать файл в искаженные символы (например, в случайные символы).
- Цель: даже если файл будет перехвачен, его содержимое невозможно расшифровать.

❁ Варианты использования совместной работы:

- Сначала используйте AES для шифрования конфиденциальных данных;
- Затем вставьте зашифрованный текст в LSB изображения. → Двойная защита: как скрывание существования (как обычные изображения), так и скрывание содержимого (для расшифровки требуется ключ)

隐写的实例

❁ 二维码中的隐写：

原理：设计一个看起来完全正常的二维码（指向一个无害网站），但在其纠错区域或通过精心设计码点图案，嵌入额外的隐藏信息（另一个URL、文本、小图片）。普通扫码软件只能读出表面信息，需要定制软件才能读出隐藏层。

示例：餐厅菜单上的二维码，扫码显示菜品介绍（公开层），但用特定APP扫描能获取隐藏的当日优惠码或内部员工信息。海报上的二维码，普通扫码是活动介绍，隐藏层是VIP邀请函。

生活场景：营销活动（寻宝、解锁优惠），内部信息传递（员工公告），版权保护（在公开二维码中嵌入所有者信息）。

要点：需要理解二维码结构（尤其是纠错码的冗余性）、需要生成双层的特殊二维码工具。

Примеры стеганографии



❁ Стеганография в QR-кодах:

Принцип: Разработайте QR-код, который выглядит совершенно нормально (указывает на безобидный веб-сайт), но включает дополнительную скрытую информацию (другой URL-адрес, текст, небольшое изображение) в область исправления ошибок или через тщательно разработанный шаблон кодовых точек. Обычное программное обеспечение для сканирования кода может считывать только поверхностную информацию. Пример: отсканируйте QR-код в меню ресторана, чтобы отобразить введение в меню (общедоступный уровень), но сканирование с помощью определенного приложения может получить скрытый код скидки дня или внутреннюю информацию о сотруднике. QR-код на плакате, обычный код сканирования — это введение к мероприятию, а скрытый слой — это URL-приглашение. Маркетинговая деятельность (поиск сокровищ, разблокировка приложений), внутренняя передача информации (объявления сотрудников), защита авторских прав (встраивание информации о владельце в публичные QR-коды).

Ключевые моменты: вам необходимо понимать структуру QR-кодов (особенно избыточно



隐写的模型

- 目前在数字媒体载体的选择上，隐写一般选择图像或视频，因为有大量的冗余空间可以插入信息。
- 而文本作为隐写载体的话，冗余度低，但其也具有灵活、内容量大等特点，可以比较容易地嵌入其他内容中。这次我们用大语言模型来介绍大模型隐写。
- 隐写（左）与水印（右）各自的过程模型如下图所示。



стеганографическая модель


- ❁ В настоящее время при выборе цифровых медианосителей для стеганографии обычно выбирают
- ❁ Как стеганографический носитель текст имеет низкую избыточность, но также обладает характеристиками гибкости и большого содержания, а также может легко встраиваться в другой контент. На этот раз мы используем большую языковую модель, чтобы представить стеганографию большой модели.
- ❁ Соответствующие модели процесса стеганографии (слева) и нанесения водяных знаков (справа)



文本隐写的分类


❁ 文本隐写主要包含两类：修改式与生成式。

❁ 近年来随着深度学习特别是大模型的发展，生成式文本隐写已经成为主流。




Классификация текстовой стеганографии

- ❁ Текстовая стеганография в основном включает две категории: модификацию и генерацию.
- ❁ В последние годы, с развитием глубокого обучения, особенно больших моделей, генератив



大模型文本隐写¹⁻³

- ❁ 文本生成模型都是“序列化”的数据。
- ❁ 当输入上文和各参数后，模型会返回一个对“next token”的预测logits表，表内是从最高概率到最低概率的token ids。
- ❁ 正常情况下，模型会根据参数来随机选择n个token中的一个来作为下一个token，然后继续循环生成。
- ❁ 而生成式隐写则是在模型推理过程中，根据设置好的规则干预模型对next token的选择，从而将想要嵌入的信息在模型推理过程中嵌入到生成文本里。



[1] Yang, Zhong-Liang, et al. "RNN-stega: Linguistic steganography based on recurrent neural networks." IEEE Transactions on Information Forensics and Security 14.5 (2018): 1280-1295.

[2] Tang, Yifan, et al. "Linguistic Steganalysis via LLMs: Two Modes for Efficient Detection of Strongly Concealed Stego." IEEE Signal Processing Letters (2024).

[3] Yang, Zhong-Liang, et al. "VAE-Stega: linguistic steganography based on variational auto-encoder." IEEE Transactions on Information Forensics and Security


Стеганография текста большой модели¹⁻³

❁ Все модели генерации текста представляют собой «сериализованные» данные.

❁ После ввода вышеуказанного и каждого параметра модель вернет таблицу прогнозируемых логитов для «следующего токена», которая содержит идентификаторы токенов от самой высокой до самой низкой вероятности.


❁ В обычных обстоятельствах модель случайным образом выберет один из n токенов в качестве следующего токена на основе параметров, а затем продолжит генерировать цикл.

❁ С другой стороны, генеративная стеганография вмешивается в выбор модели следующего токена в соответствии с установленными правилами в процессе вывода модели, тем самым внедряя информацию, которую вы хотите внедрить, в сгенерированный текст во время процесса вывода модели.




大模型文本隐写

🔴 如下图为例，假设我要嵌入被转换为的二进制的秘密信息，我可以将每次模型返回的next token的前n个编码，如当我输入“l”之后，模型返回的前8个token按概率大小顺序排列分别是have(000)、am(001)、was(010)、can(011)...每个token都能对应一个3位二进制的值，当我要隐写嵌入“001”时，我选择“am”作为next token，后面循环继续。




Текстовая стеганография большой модели

В качестве примера возьмите картинку ниже. Предположим, я хочу внедрить преобразованную двоичную секретную информацию. Я могу каждый раз кодировать первые n следующих токенов, возвращаемых моделью. Например, после того, как я ввожу «I», первые 8 токенов, возвращаемых моделью, располагаются в порядке вероятности: иметь (000), am (001), было (010), can (011)... Каждый токен может соответствовать трехзначному двоичному значению. Когда я хочу стеганографически встроить «001», я выбираю «am» в качестве следующего токена, и цикл продолжается.




大模型文本隐写

- 这里的本质上方法就是对token候选词的前n个进行编码，构造一个隐式的隐写空间，而当我想要解码信息的时候，使用相同的模型、上文、参数，那么可以保证每次模型会返回一个跟生成时完全相同的编码空间，从而反向从token来获取到原来的二进制信息流，比如从“am”反向解码得到001。




Текстовая стеганография большой модели

- Основной метод здесь — закодировать первые n слов-кандидатов токена и построить неявное стеганографическое пространство. Когда я хочу декодировать информацию, я использую ту же модель, контекст и параметры. Тогда можно гарантировать, что каждый раз модель будет возвращать пространство кодирования точно такое же, как при генерации, тем самым обратно получая исходный поток двоичной информации из токена, на пример, обратное декодирование «am» для получения 001.




大模型文本隐写

- 当然前述方法使用了非常固定的编码方法（直接按顺序对前n个token编码），下图实际上是使用霍夫曼编码方式，从而确保尽可能嵌入更多信息，提升嵌入率。



Текстовая стеганография большой модели

Конечно, вышеупомянутый метод использует очень фиксированный метод кодирования (непосредственное кодирование первых n токенов по порядку). На рисунке ниже фактически используется кодирование Хаффмана, чтобы обеспечить внедрение как можно большего количества информации и повысить скорость внедрения.



大模型隐写的意义和未来



- ❁ 大模型隐写：使用大模型进行隐写的优势是能利用大模型的性能，输出更自然、更难被发现的隐写内容。
- ❁ 编码空间：隐写的不同方法很依赖编码方式，如果有新的构造编码空间的方法，就可以创造出一门新的隐写术。
- ❁ 交叉扩展：大模型生成式文本隐写的本质是“序列化数据的循环编码”，这种技术也可以迁移到其他媒介，比如DNA也是序列化数据，可以使用仪器配合大模型输出对DNA编码进行隐写，这样可以实现军事上“把隐藏信息藏在一瓶水、一些细胞、一些毛发上”，从而实现极高水平的隐藏信息传递。
- ❁ 大模型水印：现有大模型水印技术也可以与隐写互相结合和推进。比如著名的KGW水印也是在推理过程中对next token的选择进行约束。
- ❁ 内容安全：隐写的反制技术“隐写分析（Steganalysis）”可以用于对网络媒体内容进行内容评估和筛选检测。不触发关键词的“阴阳怪气”、“网暴骂人”本质上也是一种“隐写”，因此也有被人工智能使用隐写检测的方法自动侦测到的可能性，这将有利于未来人类网络空间安全的维护。



Значение и будущее стеганографии больших моделей



- ❁ Стеганография больших моделей. Преимущество использования больших моделей для стеганографии заключается в том, что можно использовать преимущества производительности больших моделей для вывода стеганографического содержимого, которое является более естественным и трудным для обнаружения.
- ❁ Пространство кодирования. Различные методы стеганографии зависят от метода кодирования. Если существует новый метод построения пространства кодирования, можно создать новую стеганографию.
- ❁ Перекрестное расширение. Суть стеганографии генеративного текста большой модели заключается в «циклическом кодировании сериализованных данных». Эту технологию также можно перенести на другие носители. Например, ДНК также представляет собой сериализованные данные. Вы можете использовать инструменты и результаты больших моделей для стеганографического кодирования ДНК. Таким образом, в армии можно «спрятать скрытую информацию в бутылке с водой, некоторых клетках и волосах», тем самым достигая очень высокого уровня передачи скрытой информации.
- ❁ Нанесение водяных знаков на большие модели. Существующая технология нанесения водяных знаков на большие модели также можно комбинировать и совершенствовать со стеганографией. Например, знаменитый водяной знак KGW также ограничивает выбор следующего токена в процессе вывода.
- ❁ Безопасность контента. Стеганализ, технология противодействия стеганографии, может использоваться для оценки, проверки и обнаружения контента онлайн-медиа. «Странности Инь и Ян» и «киберзлоупотребления», которые не вызывают ключевые слова, по сути являются своего рода «стеганографией», поэтому существует также возможность автоматического обнаружения искусственным интеллектом с использованием методов обнаружения стеганографии, что будет полезно для поддержания безопасности человеческого киберпространства в будущем.

