



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Практическое изучение ст

张玉龙

—— 饮水思源 · 爱国荣校 ——

Применение больших моделей в защищенных коммуникациях



- ❁ Стеганография — это технология сокрытия информации, основной целью которой является внедрение информации в различные носители (например, цифровые изображения, аудио, видео или текст) для достижения скрытой связи. Стеганография отличается от технологии шифрования тем, что она не только скрывает содержание информации, но и скрывает существование способа передачи информации. Эта технология использует нечувствительность системы восприятия человека к определенной информации и скрывает секретную информацию в избыточной информации цифровых носителей, в результате чего информация на поверхности выглядит такой же, как и на обычных носителях, что затрудняет ее обнаружение злоумышленниками.
- ❁ Приложения стеганографии включают, помимо прочего, скрытую передачу, защиту авторских прав и т. д. С развитием технологий стеганография становится все более важной в военной, коммерческой и других областях, а также обеспечивает удобство для злонамеренного поведения, такого как шпионаж, террористические атаки и т. д.



Значение стеганографии

- ❁ Проще говоря, стеганография — это метод безопасной передачи информации, отличный от шифрования.
- ❁ Пароль представляет собой «зашифрованный» простой текст, так что содержимое передаваемого сообщения не может быть получено посредником, но посредник может обнаружить и получить информацию о носителе доставки сообщения, чтобы подделать и перехватить доставку сообщения.
- ❁ Стеганография призвана «скрыть» факт доставки сообщения. Содержание сообщения, которое должно быть доставлено, скрыто на общедоступном канале и замаскировано под общий контент. Цель состоит в том, чтобы только получатель сообщения мог обнаружить скрытое сообщение, а не посредник.

Простые случаи стеганографии в реальной жизни: стихи-акrostихи, небольшие заметки в книгах.

Последующая производная технология стеганографии: водяные знаки (которые можно понимать как разновидность стеганографии, которая уделяет больше внимания надежности и желает, чтобы ее обнаруживали и интерпретировали многие люди).

Примеры стеганографии по сравнению с паролями



❁ Стеганография (текстовый формат):

- Операция: отрегулируйте интервал между буквами (например, разницу в 0,1 пт) и цвет шрифта (#000000 вместо #010101) в электронном документе и используйте информацию о двоичном кодировании (например, «большой интервал = 1, обычный = 0») 1.
- Цель: Информация скрыта в общедоступных текстах и не видна невооруженным глазом

❁ Криптография (шифр Вирджинии):

- Действие: Используйте повторное шифрование по ключевому слову (например, ключ «1
- Цель: создать искаженный зашифрованный текст, требующий расшифровки с помощью
- контраст:
 - Стеганография: Перевозчик является обычным документом (например, договором)
 - Криптография: сам зашифрованный текст показывает, что «секрет существует», но е



Примеры стеганографии

❁ Стеганография (изображение LSB):

- Операция: изменить младшие биты (LSB) пикселей изображения и внедрить секретные данные (например, двоичный файл другого изображения). Человеческий глаз не может обнаружить разницу, но инструменты могут ее выделить²⁹.
- Цель: скрыть информацию на обычных фотографиях (например, фотографиях из путешествий).

❁ Криптография (AES-256):

- Операция: используйте ключ, чтобы зашифровать файл в искаженные символы (например, в случайные символы).
- Цель: даже если файл будет перехвачен, его содержимое невозможно расшифровать.

❁ Варианты использования совместной работы:

- Сначала используйте AES для шифрования конфиденциальных данных;
- Затем вставьте зашифрованный текст в LSB изображения. → Двойная защита: как скрывание существования (как обычные изображения), так и скрывание содержимого (для расшифровки требуется ключ)

Примеры стеганографии



❁ Стеганография в QR-кодах:

Принцип: Разработайте QR-код, который выглядит совершенно нормально (указывает на безобидный веб-сайт), но включает дополнительную скрытую информацию (другой URL-адрес, текст, небольшое изображение) в область исправления ошибок или через тщательно разработанный шаблон кодовых точек. Обычное программное обеспечение для сканирования кода может считывать только поверхностную информацию. Пример: отсканируйте QR-код в меню ресторана, чтобы отобразить введение в меню (общедоступный уровень), но сканирование с помощью определенного приложения может получить скрытый код скидки дня или внутреннюю информацию о сотруднике. QR-код на плакате, обычный код сканирования — это введение к мероприятию, а скрытый слой — это URL-приглашение. Маркетинговая деятельность (поиск сокровищ, разблокировка приложений), внутренняя передача информации (объявления сотрудников), защита авторских прав (встраивание информации о владельце в публичные QR-коды).

Ключевые моменты: вам необходимо понимать структуру QR-кодов (особенно избыточно


стеганографическая модель

- ❁ В настоящее время при выборе цифровых медианосителей для стеганографии обычно выбирают
- ❁ Как стеганографический носитель текст имеет низкую избыточность, но также обладает характеристиками гибкости и большого содержания, а также может легко встраиваться в другой контент. На этот раз мы используем большую языковую модель, чтобы представить стеганографию большой модели.
- ❁ Соответствующие модели процесса стеганографии (слева) и нанесения водяных знаков (справа)



Классификация текстовой стеганографии

- ❁ Текстовая стеганография в основном включает две категории: модификацию и генерацию.
- ❁ В последние годы, с развитием глубокого обучения, особенно больших моделей, генеративная




Стеганография текста большой модели¹⁻³

❁ Все модели генерации текста представляют собой «сериализованные» данные.

❁ После ввода вышеуказанного и каждого параметра модель вернет таблицу прогнозируемых логитов для «следующего токена», которая содержит идентификаторы токенов от самой высокой до самой низкой вероятности.

❁ В обычных обстоятельствах модель случайным образом выберет один из n токенов в качестве следующего токена на основе параметров, а затем продолжит генерировать цикл.

❁ С другой стороны, генеративная стеганография вмешивается в выбор модели следующего токена в соответствии с установленными правилами в процессе вывода модели, тем самым внедряя информацию, которую вы хотите внедрить, в сгенерированный текст во время процесса вывода модели.




[1] Yang, Zhong-Liang, et al. "RNN-stega: Linguistic steganography based on recurrent neural networks." IEEE Transactions on Information Forensics and Security 14.5 (2018): 1280-1295.

[2] Tang, Yifan, et al. "Linguistic Steganalysis via LLMs: Two Modes for Efficient Detection of Strongly Concealed Stego." IEEE Signal Processing Letters (2024).

[3] Yang, Zhong-Liang, et al. "VAE-Stega: linguistic steganography based on variational auto-encoder." IEEE Transactions on Information Forensics and Security 16 (2020): 880-895.


Текстовая стеганография большой модели

В качестве примера возьмите картинку ниже. Предположим, я хочу внедрить преобразованную двоичную секретную информацию. Я могу каждый раз кодировать первые n следующих токенов, возвращаемых моделью. Например, после того, как я ввожу «I», первые 8 токенов, возвращаемых моделью, располагаются в порядке вероятности: иметь (000), am (001), было (010), can (011)... Каждый токен может соответствовать трехзначному двоичному значению. Когда я хочу стеганографически встроить «001», я выбираю «am» в качестве следующего токена, и цикл продолжается.




Текстовая стеганография большой модели

- Основной метод здесь — закодировать первые n слов-кандидатов токена и построить неявное стеганографическое пространство. Когда я хочу декодировать информацию, я использую ту же модель, контекст и параметры. Тогда можно гарантировать, что каждый раз модель будет возвращать пространство кодирования точно такое же, как при генерации, тем самым обратно получая исходный поток двоичной информации из токена, на пример, обратное декодирование «am» для получения 001.



Текстовая стеганография большой модели

Конечно, вышеупомянутый метод использует очень фиксированный метод кодирования (непосредственное кодирование первых n токенов по порядку). На рисунке ниже фактически используется кодирование Хаффмана, чтобы обеспечить внедрение как можно большего количества информации и повысить скорость внедрения.



Значение и будущее стеганографии больших моделей



- ❁ Стеганография больших моделей. Преимущество использования больших моделей для стеганографии заключается в том, что можно использовать преимущества производительности больших моделей для вывода стеганографического содержимого, которое является более естественным и трудным для обнаружения.
- ❁ Пространство кодирования. Различные методы стеганографии зависят от метода кодирования. Если существует новый метод построения пространства кодирования, можно создать новую стеганографию.
- ❁ Перекрестное расширение. Суть стеганографии генеративного текста большой модели заключается в «циклическом кодировании сериализованных данных». Эту технологию также можно перенести на другие носители. Например, ДНК также представляет собой сериализованные данные. Вы можете использовать инструменты и результаты больших моделей для стеганографического кодирования ДНК. Таким образом, в армии можно «спрятать скрытую информацию в бутылке с водой, некоторых клетках и волосах», тем самым достигая очень высокого уровня передачи скрытой информации.
- ❁ Нанесение водяных знаков на большие модели. Существующая технология нанесения водяных знаков на большие модели также можно комбинировать и совершенствовать со стеганографией. Например, знаменитый водяной знак KGW также ограничивает выбор следующего токена в процессе вывода.
- ❁ Безопасность контента. Стеганализ, технология противодействия стеганографии, может использоваться для оценки, проверки и обнаружения контента онлайн-медиа. «Странности Инь и Ян» и «киберзлоупотребления», которые не вызывают ключевые слова, по сути являются своего рода «стеганографией», поэтому существует также возможность автоматического обнаружения искусственным интеллектом с использованием методов обнаружения стеганографии, что будет полезно для поддержания безопасности человеческого киберпространства в будущем.

